

ANALYSE ET PRÉDICTION DU RISQUE DE CRÉDIT DE PRÊT

PROJET DATAMINING

Team
Discovery
23/04/23

GUI Yiming
GASSIHOUN Yao Guershom
ZHANG Ruijie
HE Xi

MIAGE - ISIAD

Tableau des matières

Tableau des matières	1
Introduction	2
1. Présentation du jeu de données	2
1.1. Détection des données	3
1.2. Nettoyage des données	6
1.3. Intégration	7
1.4. Transformation	7
2. Hypothèses	8
3. Description des analyses	8
3.1. Importance et corrélation des données avec loan status	8
3.2. Corrélation entre les intentions de prêt et l'âge	10
3.3. Corrélation entre le ratio prêt/la notation du prêt et loan status	12
4. Présentation des résultats	13
4.1. Importance et corrélation des données avec loan status	13
4.2. Corrélation entre les intentions de prêt et l'âge	14
4.3. Corrélation entre le ratio prêt/la notation du prêt et loan status	14
5. Modèles prédictifs	14
Conclusion générale	15

Introduction

Le but de ce projet est de mieux comprendre l'évolution de l'information sur le crédit en analysant les différents indicateurs des prêteurs et les relations entre eux.

Les analyses doivent permettre de fournir une référence visuelle et une prédiction de modèle pour les banques ou les prêteurs lors des prêts. Par exemple, identifier trois indicateurs que les banques ou les prêteurs observent principalement lors de la confirmation des prêts; Utiliser des modèles prédictifs pour prédire l'état des prêts des prêteurs; déterminer l'objectif principal du prêt pour différents groupes d'âge; Confirmer la corrélation entre le ratio de prêt, le degré du prêt et le statut du prêt.

Cette recherche a commencé par l'étude des données à disposition en cherchant à les classer puis à les explorer afin d'en déduire des résultats.

L'étude montre que les facteurs importants sont le revenu, le ratio prêt/revenu et le taux d'intérêt du prêt, qui peuvent être des prédicteurs importants de la défaillance d'une personne sur un prêt; Il existe un lien certain entre l'âge et le fait de contracter un prêt, ce qui peut influencer sur la décision de contracter un prêt et sur l'intention de le faire; Plus le ratio prêt/valeur est élevé et plus la probabilité de défaillance est grande.

1. Présentation du jeu de données



Le fichier contenant les données a été téléchargé sur le site Kaggle. Il comporte 32 581 lignes et les 12 colonnes suivantes avec leur description :


Feature Name	Description
person_age	Age
person_income	Annual Income
person_home_ownership	Home ownership
person_emp_length	Employment length (in years)
loan_intent	Loan intent
loan_grade	Loan grade
loan_amnt	Loan amount
loan_int_rate	Interest rate

loan_status	Loan status (0 is non default 1 is default)
loaxn_percent_income	Percent income
cb_person_default_on_file	Historical default
cb_preson_cred_hist_length	Credit history length

1.1. Détection des données




Avant de commencer l'analyse, nous avons fait des observations sur les données. Tout d'abord, pour les données numériques, nous avons utilisé le modèle Boxplot pour les observations. Comme le montrent les six graphiques ci-dessous, pour la colonne des âges, la plupart des âges se situent dans la fourchette 20-40 ans, certains étant concentrés dans la fourchette 40-90 ans, et quelques-uns dépassent 90 ans, voire 140 ans, cette valeur est en dehors de la fourchette d'âge normale. Pour la colonne "ancienneté", la majorité des années de service se situent entre 0 et 18 ans, avec quelques concentrations entre 18 et 50 ans. Un chiffre indique 120 années de service, ce qui est clairement une anomalie et des données incorrectes. Pour la colonne des revenus annuels, la plupart des revenus annuels sont compris entre 0 et 2,3 (*1e6), tandis qu'il existe également des valeurs trop élevées telles que 6*1e6, que nous considérons comme des valeurs aberrantes. Pour la colonne du montant du prêt, la plupart des prêts se situent dans la fourchette 0-22 500, tandis que certains prêts sont concentrés dans la fourchette 22 500-35 000. Dans la colonne des taux d'intérêt, la plupart des taux d'intérêt sont compris entre 5 et 22, quelques-uns étant supérieurs à 22,5. Dans la colonne des ratios prêt/revenu, la plupart des ratios prêt/revenu sont compris entre 0 et 0,45, certains étant concentrés entre 0,45 et 0,8.





Pour les données relatives aux types de caractères, nous utilisons des diagrammes à barres pour l'observation. Comme le montrent les trois graphiques ci-dessous, pour la colonne sur la propriété du logement, la majorité des personnes possèdent un logement locatif, tandis que la majorité des personnes possèdent un logement hypothéqué et que seule une minorité est propriétaire de son logement. Dans la colonne sur l'intention d'emprunter, les gens empruntent pour diverses raisons : raisons personnelles, raisons d'études, raisons médicales, raisons professionnelles, amélioration de l'habitat, raisons d'endettement, la plus importante étant les raisons d'études. Pour la colonne sur l'échelle d'emprunt, il y a 7 échelles différentes de A à G, l'échelle augmentant dans l'ordre, plus l'échelle est élevée, plus le risque est élevé, on peut observer que les échelles A et B sont les échelles les plus fréquentes.

Discovery



Pour les colonnes Statut d'emprunt et Historique des violations d'emprunt, les types de données et les résultats ont été observés : un statut d'emprunt de 0 signifie que le statut d'emprunt actuel est bon, et un statut d'emprunt de 1 signifie que le statut d'emprunt actuel est en défaillance. Un historique de violation d'emprunt de N indique qu'il n'y a pas d'historique de violation et un historique de violation d'emprunt de Y indique qu'il y a un historique de violation.

```
In [ ]: #voir s'il existe des données non-binaire sur certains colonnes

n [161]: df.loan_status.value_counts()

Out[161]: 0    24651
          1    6798
          Name: loan_status, dtype: int64

n [158]: df.cb_person_default_on_file.value_counts()

Out[158]: N    25877
          Y    5572
          Name: cb_person_default_on_file, dtype: int64
```

Après vérification des données, nous avons constaté qu'il existe des données nulles pour les colonnes Propriété, Nombre d'années de travail, Taux d'emprunt et Montant de l'emprunt. En particulier, le nombre d'années d'emploi et le taux d'intérêt du prêt sont particulièrement élevés.

```
#df.isna().sum() #compter Le nombre de données vide pour chaque colonne

]: person_age           0
   person_income        0
   person_home_ownership 1
   person_emp_length    895
   loan_intent          0
   loan_grade           0
   loan_amnt            1
   loan_int_rate       3116
   loan_status          0
   loan_percent_income  0
   cb_person_default_on_file 0
   cb_person_cred_hist_length 0
   dtype: int64
```

Nous avons aussi remarqué que les types des données sont aussi détectés automatiquement et qu'il n'y a pas besoin d'effectuer des transformations ou adaptations là dessus.

1.2. Nettoyage des données

Le fichier donné en format csv est bien structuré et les noms de colonnes explicites. Les modifications effectuées pour une bonne qualité des données ont été les suivantes :

- Elimination des valeurs inapplicable : l'âge est inférieur à 90 ans, les années de service sont inférieures à 100, le revenu annuel est inférieur à 250 000 euros.
- Sauvegarde des données nettoyées (avec les colonnes N/A pour colonne person_emp_length) dans un autre fichier (data_nétoyé.csv).

- Remplacement des valeurs N/A pour colonne `person_emp_length` : Nous avons utilisé plutôt la moyenne de cette colonne.
- Sauvegarde des données nettoyées (sans colonne vide) dans un autre fichier (`data_nétoyé_sansNa.csv`) pour en faire hypothèse 1.

Exemple de données initiales :

```

M with open('credit_risk_dataset.csv', mode='r') as f:#Ouvrir Le fichier de dataset et pré-Lire Le premier 10 lignes
    for i in range(10):
        print(f.readline(), end='')

person_age,person_income,person_home_ownership,person_emp_length,loan_intent,loan_grade,loan_amnt,loan_int_rate,loan_status,
loan_percent_income,cb_person_default_on_file,cb_person_cred_hist_length
90,59000,,123.0,PERSONAL,D,,16.02,1,0.59,Y,3
22,59000,RENT,123.0,PERSONAL,D,35000,16.02,1,0.59,Y,3
21,9600,OWN,5.0,EDUCATION,B,1000,11.14,0,0.1,N,2
25,9600,MORTGAGE,1.0,MEDICAL,C,5500,12.87,1,0.57,N,3
23,65500,RENT,4.0,MEDICAL,C,35000,15.23,1,0.53,N,2
24,54400,RENT,8.0,MEDICAL,C,35000,14.27,1,0.55,Y,4
21,9900,OWN,2.0,VENTURE,A,2500,7.14,1,0.25,N,2
26,77100,RENT,8.0,EDUCATION,B,35000,12.42,1,0.45,N,3
24,78956,RENT,5.0,MEDICAL,B,35000,11.11,1,0.44,N,4

```

Exemple de données après le nettoyage :

```

M df = df[df.person_age <= 90] #Filter Les personnes étant trop âgées
df = df[df.person_emp_length <= 100]#Filtrer Les personnes ayant trop d'années d'être employés
df = df[df.person_income <= 250000]#Filtrer quelques personnes ayant trop d'écart de salaire
#pour faciliter l'observation des distribution de données

df # résultat en supprimant Les données ayant Les valeurs excessivement élevées

```

8]:

	person_age	person_income	person_home_ownership	person_emp_length	loan_intent	loan_grade	loan_amnt	loan_int_rate	loan_status
2	21	9600	OWN	5.0	EDUCATION	B	1000.0	11.14	0
3	25	9600	MORTGAGE	1.0	MEDICAL	C	5500.0	12.87	1
4	23	65500	RENT	4.0	MEDICAL	C	35000.0	15.23	1
5	24	54400	RENT	8.0	MEDICAL	C	35000.0	14.27	1
6	21	9900	OWN	2.0	VENTURE	A	2500.0	7.14	1
...	...	...	...	...	...	...	...	...	...
32577	57	53000	MORTGAGE	1.0	PERSONAL	C	5800.0	13.16	0
32578	54	120000	MORTGAGE	4.0	PERSONAL	A	17625.0	7.49	0
32579	65	76000	RENT	3.0	HOMEIMPROVEMENT	B	35000.0	10.99	1
32580	56	150000	MORTGAGE	5.0	PERSONAL	B	15000.0	11.48	0
32581	66	42000	RENT	2.0	MEDICAL	B	6475.0	9.99	0

Au total, 1 132 lignes ont été supprimées, ce qui laisse 31 449 lignes, ce qui reste très élevé mais cela ne devrait pas avoir d'impact sur les analyses futures.

1.3. Intégration

Les données dont nous disposons nous fournissant des informations nécessaires à l'analyse, nous avons souhaité ne pas intégrer d'autres données.

1.4. Transformation

Cette étape de transformation utilise le fichier `data_nétoyé_sansNa.csv`. Afin d'afficher toutes les catégories, par exemple les catégories de prêt, il affiche A-G séparément, et les

intentions de prêt, etc., il affiche également toutes les catégories dans l'en-tête du tableau, de sorte que la situation spécifique d'une personne soit plus claire et que nous puissions préparer la première hypothèse, les deux autres hypothèses n'utilisant pas ces données de transfert.

J: `JICAL`

	loan_intent_PERSONAL	loan_intent_VENTURE	loan_grade_A	loan_grade_B	loan_grade_C	loan_grade_D	loan_grade_E	loan_grade_F	loan_grade_G
0	1	0	0	0	0	1	0	0	0
0	1	0	0	0	0	1	0	0	0
0	0	0	0	1	0	0	0	0	0
1	0	0	0	0	1	0	0	0	0
1	0	0	0	0	1	0	0	0	0

2. Hypothèses

Les hypothèses qu'on tentera de vérifier sont les suivantes :

1. La banque ou le prêteur doit tenir compte de la part de revenu du prêteur, de son niveau d'emprunt et de ses antécédents en matière de défaillance lorsqu'il accorde un prêt.
2. Les intentions de prêts populaires évoluent avec l'âge.
3. Plus le ratio prêt/valeur est élevé, plus la notation du prêt est élevée et plus la probabilité de défaillance est grande.

3. Description des analyses

3.1. Importance et corrélation des données avec loan status

Les modèles ont d'abord été construits à l'aide de pycaret et les différents modèles ont été comparés pour trouver le meilleur modèle à utiliser. Pour notre jeu de données, il a été conclu que lightgbms était le meilleur modèle à utiliser. Nous construisons donc un modèle lightgbms à l'aide de create_model et utilisons ensuite plot_model pour présenter les résultats.

Le graphique ci-dessous montre le classement des 10 premiers dans l'importance de l'impact de chaque attribut dans l'ensemble de données sur les conditions de prêt. Nous pouvons voir que le revenu annuel d'un individu est le facteur le plus important affectant le statut du prêt, ce qui est beaucoup plus important que d'autres données, qui est 8 fois la durée de l'historique(vie) du crédit. Ce qui est tout à fait normal parce que le revenu annuel de l'emprunteur permet de déterminer sa solvabilité et de minimiser la possibilité de tomber en impayé.

Discovery


Le taux d'intérêt d'un prêt est le deuxième facteur le plus important affectant le statut d'un prêt. Il permet à l'emprunteur d'évaluer les mensualités que doit payer l'emprunteur pour éviter qu'il y ait des retards de paiement.

La troisième est la proportion des revenus du prêt et le montant du prêt. Il permet de déterminer approximativement le montant à prêter.

L'âge du prêteur et le nombre d'années pendant lesquelles le prêteur a travaillé dans une mesure similaire sur le statut du prêt. Cela peut s'expliquer par ce critère permettra d'évaluer la stabilité financière et professionnelle de l'emprunteur.

La location d'une maison a un peu plus d'influence que la possession d'une maison; cela peut s'expliquer par le fait que les propriétaires ont des taxes qui s'appliquent.


La longueur de l'historique(vie) du crédit est le facteur le moins important qui affecte le statut d'un prêt. Ce qui est un peu normal parce que la situation présente de l'emprunteur est plus déterminante.



Une matrice de corrélation croisée est utilisée pour examiner la corrélation avant chaque colonne de données et, enfin, une carte thermique est utilisée pour visualiser ces corrélations. En utilisant cette carte thermique de la matrice de corrélation croisée, nous pouvons voir que les données les plus pertinentes pour le statut du prêt sont le ratio prêt/revenu (0,38), le taux d'intérêt du prêt (0,34), le statut du revenu (-0,22) et le montant du prêt (0,12). Le reste des données n'est pas bien corrélé avec le statut du prêt.

Discovery

Le statut du revenu ayant une corrélation négative avec le montant du prêt indique que plus le montant est élevé, plus le taux de remboursement est élevé pouvant s'expliquer par la solvabilité des emprunteurs aux revenus élevés.




3.2. Corrélation entre les intentions de prêt et l'âge


Afin de visualiser l'influence de l'âge sur les différentes intentions de prêt, il a été décidé d'utiliser une ligne de crête. Le Ridgeline plot peut montrer la distribution d'une valeur numérique pour plusieurs groupes.

Comme le montre le graphique ci-dessous, les coordonnées horizontales divisent les âges en différents stades et les coordonnées verticales circonscrivent les différentes intentions de prêt. En regardant l'image, nous voyons que la majorité de l'âge des emprunteurs se situe entre 20 et 35 ans. Les intentions de prêt les plus évidentes sont les études et la création d'entreprise.

Ridgeline Plot de loan intend en fonction de l'age



Le graphique ci-dessous nous permet de voir plus clairement comment les intentions de prêt se comparent entre les différents groupes d'âge. Nous définissons les moins de 25 ans comme de jeunes adultes, les 25-45 ans comme des adultes, les 45-55 ans comme des personnes d'âge moyen et les 55 ans et plus comme des personnes plus âgées. Les intentions de prêt des jeunes sont principalement axées sur les études, celles des adultes sur les soins de santé, celles des personnes d'âge moyen sur les soins de santé et certains facteurs personnels, et celles des personnes plus âgées également sur les facteurs personnels. Le nombre de jeunes et d'adultes qui contractent des prêts est important, et le nombre de personnes qui contractent des prêts diminue au fur et à mesure qu'elles vieillissent.




3.3. Corrélation entre le ratio prêt/la notation du prêt et loan status

Utilisez le Boxplot pour combiner le statut du loan avec les ratios prêt/revenu et les degrés de loan afin de voir dans quelle mesure le statut du loan est affecté par les ratios prêt/revenu et les degrés de loan.

Les coordonnées horizontales de ce graphique sont les notes des prêts et les coordonnées verticales sont les taux des prêts. Le bleu indique une défaillance, le rose indique l'absence de défaillance.

Le graphique ci-dessous montre que le nombre de bons états de prêt diminue à mesure que le niveau de prêt augmente, en particulier pour les niveaux de risque élevés où le nombre de bons états de prêt est proche de zéro. Un ratio prêt/revenu élevé est associé à un grand nombre de prêts en défaut de paiement. Les niveaux A et B sont les deux numéros de prêt les plus élevés.



4. Présentation des résultats

4.1. Importance et corrélation des données avec loan status

L'image de feature plot montre que chaque colonne a un impact différent sur le statut du prêt, les trois principales influences étant le revenu, le taux d'intérêt sur le prêt et le ratio du prêt par rapport au revenu. Les catégories de prêts et les défaillances historiques dans notre hypothèse ne sont même pas indiquées dans ce graphique parce qu'elles sont moins importantes (seules les dix premières sont indiquées dans le graphique).

La matrice des corrélations croisées montre que les trois corrélations les plus pertinentes pour l'état de la boucle sont également le revenu, le taux d'intérêt sur le prêt et le ratio du prêt par rapport au revenu.

L'analyse des données nous a permis de conclure que les facteurs de cet ensemble de données qui ont le plus d'impact sur le statut d'un prêt (qu'il soit ou non en défaut de paiement) sont le salaire de l'emprunteur, le taux d'intérêt du prêt et le ratio du prêt par rapport au salaire. Ce sont les trois facteurs qu'il convient d'examiner en premier lieu pour déterminer si un emprunteur va se trouver en situation de défaut de paiement. En revanche, la corrélation linéaire entre la qualité du prêt et l'historique des défaillances et le statut du prêt est faible, ce qui indique que la qualité du prêt et l'historique des défaillances ne sont pas des facteurs significatifs affectant le statut du prêt.

4.2. Corrélation entre les intentions de prêt et l'âge

L'image de la ligne de crête montre que pour chacune des intentions de prêt, l'âge culmine entre 20 et 30 ans, ce qui permet de conclure que les personnes âgées de 20 à 30 ans sont les plus susceptibles de contracter un prêt. La différence peut être observée en comparant les différentes intentions de prêt, par exemple, les intentions de prêt des jeunes de moins de 25 ans sont axées sur l'éducation, celles des adultes de 25 à 45 ans sur les soins de santé, celles des personnes d'âge moyen de 45 à 55 ans sur les soins de santé et certains facteurs personnels, et celles des personnes âgées de 55 ans et plus sur les facteurs personnels. Le nombre de jeunes et d'adultes qui contractent des prêts est élevé et diminue avec l'âge.

4.3. Corrélation entre le ratio prêt/revenu et le statut du prêt et loan status

Le Boxplot montre que la catégorie de prêt a peu d'effet sur l'état du prêt, seule la catégorie G affichant un taux de défaillance significativement plus élevé que le taux de non-défaillance. D'autre part, les ratios prêt/revenu ont toujours un impact sur le statut du prêt. Les emprunteurs dont le ratio prêt/revenu est élevé sont plus susceptibles de ne pas rembourser que ceux dont le ratio prêt/revenu est faible, quelle que soit leur degré de prêt. Cela suggère que le degré de prêt n'est pas le critère le plus important pour prédire si une personne fera défaut sur un prêt, mais que c'est plutôt le ratio prêt/revenu qui est le critère important. Plus le ratio est élevé, plus le risque du prêt est important.

5. Modèles prédictifs

Le processus de création du modèle prédictif a pour objectif de prévoir la probabilité de défaillance du prêteur.

Avant la construction du modèle, nous avons séparé les parties des données afin de tester le modèle.

Pour établir ce modèle, d'abord nous avons réparti le jeu de prédiction par jeu d'entraînement de celui de test pour construire le modèle de prédiction à l'aide du framework Light Bgm. Ensuite, pour évaluer ce modèle, nous avons calculé la note de rappel à partir du jeu d'entraînement et la note de précision par rapport au jeu de test, nous avons paramétré 0.5 comme seuil de probabilité en pourcentage pour bien distinguer le résultat de défaillance en binaire, les résultats comme suivante :

le précision est : 0.9500597532977655

le rappel est 0.9362378756559071

Enfin, pour réutiliser ce modèle, il a fallu d'abord importer le nouveau fichier csv de dataset et ensuite exécuter ce modèle avec ce dataset en entrée comme lva photo suivante. Pour connaître la précision, nous avons utilisé le même processus de calcul, comme la photo

Discovery

l'illustre. Pour la note de rappel, tous les résultats prévus par ce modèle correspondaient à un nouveau jeu de données appelé `test_df`.

Utiliser le modèle prédiction avec dataset de test en entrée :

```
res = clf.predict(test_df[test_features])  
res
```

le note de précision :

```
le rappel est 1.0
```

Conclusion générale

En conclusion, les résultats des 3 analyses montrent que :

- Les facteurs importants qui influencent le statut du prêt sont le revenu, le ratio prêt/revenu et le taux d'intérêt du prêt, qui peuvent être des prédicteurs importants de la défaillance d'une personne sur un prêt.
- Il existe un lien certain entre l'âge et le fait de contracter un prêt, ce qui peut influencer sur la décision de contracter un prêt et sur l'intention de le faire.
- Plus le ratio prêt/revenu est élevé, et plus la probabilité de défaillance est grande.